

L^AT_EX Laboratorio Imágenes: Histogramas y filtros lineales

Juan Camilo Bustamante
Universidad de los Andes
jc.bustamante@uniandes.edu.co

Christian Picón
Universidad de los Andes
c.picon@uniandes.edu.co

1. Cross Correlación

1. Las condiciones de frontera determinan el tratamiento que se debe realizar con los bordes de la imagen. Esto es importante, ya que al aplicar un kernel de $m \times m$ a los píxeles en los bordes de la imagen, no hay suficientes píxeles adyacentes para completar el número necesario para operar con el kernel. En este punto se utilizó los métodos de condiciones de frontera fill, el cual rodea con ceros los bordes de la imagen. El método symmetric consiste en reflejar los bordes de la imagen original dependiendo del tamaño del kernel. Y por último, se aplicó el método valid, el cual solo permite aplicar el kernel sobre los puntos que permiten abarcar con sus vecinos el tamaño del kernel [1]. Este último tiene la peculiaridad que reduce la imagen resultante de la cross-correlación debido a que solo se aplica el kernel en los píxeles interiores que pueden abarcar el tamaño de la ventana del kernel.

2. Se aplicaron los siguientes kernels a una matriz de unos de tamaño 3×3 :




Figure 1. (a) Kernel 1, (b) Kernel 2 y (c) Kernel3




Figure 2. Resultado de la cross correlación con distintos kernels

Como se observa en la anterior imagen, el primer kernel solo realiza una suma de los píxeles superiores del píxel central al cual se le está realizando la Cross-correlación. En conclusión, desplaza la imagen una fila hacia abajo. El segundo kernel realiza los bordes verticales. El tercero, aunque

no es muy observable, permite reducir el ruido, suavizar falsos contornos y eliminar pequeños detalles [2].

3. Como se observa en la siguiente imagen, al aplicar un kernel saturado (la suma de sus componentes es mayor a 1) a la imagen, su resultante tiene valores por encima de la capacidad de almacenamiento. En consecuencia, la imagen se visualiza con blanco todos los píxeles mayores a 255 para el caso de formatos uint8.



Figure 3. Resultado de la crosscorrelación con distintos kernels

4. Al comparar con la función correlate2d se obtuvo un error cuadrático medio de cero para todos los métodos de condiciones de contorno usados.

2. Aplicación de la cross-correlación

2. A continuación en las figuras 4 y 5 se muestran las respuestas de cada imagen al ser filtrada con cada kernel




Figure 4. Respuesta de cada imagen al ser filtrada con cada kernel




Figure 5. Respuesta de cada imagen al ser filtrada con cada kernel

3. En la figura 6 se muestran los histogramas de las respuestas de cada imagen al ser filtrada con cada kernel

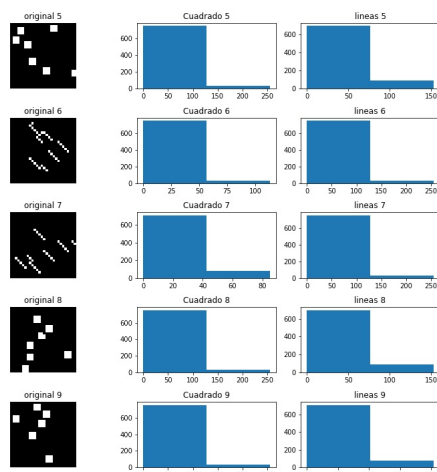


Figure 6. Histogramas de las respuestas de cada imagen al ser filtrada con cada kernel

4. Se filtraron imágenes en blanco y negro que dieron como resultado imágenes en escala de grises. Esto quiere decir que los píxeles en escala de grises son artefactos producto de la filtración. Las zonas mas claras muestran mayor influencia de la zona blanca en el filtro del píxel. Esta influencia puede ser producto de mayor peso en el kernel de filtrado, o mayor presencia de zona blanca dentro del kernel.

3. Clasificación de enfermedades

3. En el método 1 la clase con menor precisión fue la 4 con un valor de 0.491429. En el 2 fue la clase 1 y en el 3 fue la clase 4. Por otro lado, la clase más fácil fue la 3 para todos métodos, con un valor 0.792793 para el método 1, 0.411765 para el método 2 y 0.792793 para el método

Método	ACA
Método 3	0.641
Método 1	0.602
Método 2	0.206

Table 1. Resultados del challenge

3. En consecuencia, se puede inferir que la clase tres puede tener más cantidad de datos respecto al total del dataset. Este factor de desbalance puede generar una ventaja para la clase más prominente en los algoritmos de clasificación

4. El ACA en un problema de clasificación es una forma de medir que tan efectivo es nuestro algoritmo clasificando una imagen en un grupo de categorías semánticas predeterminadas.[2] Es importante resaltar que se deben tener cantidades similares de imágenes para cada categoría. Para obtener el ACA, se crea primero una matriz de confusión (predicciones vs anotaciones), se normaliza con respecto a las anotaciones, y se obtiene el promedio de la diagonal.

Cada columna de la matriz representa el número de predicciones para cada clase, mientras que cada fila representa las instancias en la clase real.[2] Uno de los ventajas que presentan las matrices de confusión es que facilitan notar si el sistema está confundiendo dos clases.

El método con mejor desempeño fue el método 3 y el ACA correspondiente para cada método se muestra en la tabla 1

4. Referencias

[1] “`scipy.signal.correlate2d¶`,” `scipy.signal.correlate2d` - SciPy v1.3.0 Reference Guide. [Online]. Available: <https://docs.scipy.org/doc/scipy/reference/generated/scipy.signal.correlate2d.html>. [Accessed: 15-Sep-2019].

[2] P. Arbelaez, “Filtrado espacial,” in *Análisis y procesamiento de imágenes biomédicas*, 04-Sep-2019.

Realizado en L^AT_EX